

Por que se nos van los clientes, y que hacer al respecto

Analisis de 5.630 clientes de e-commerce para identificar las senales mas fuertes de abandono y un modelo que prioriza a quien contactar antes de perderlo.

16,8%

de los clientes
abandona la marca

173/190

clientes que se iban,
el modelo los detecto
a tiempo

5

hipotesis de negocio
validadas con datos

01 Resumen ejecutivo

Analizamos 5.630 clientes de e-commerce para entender por que abandonan y construimos un modelo que anticipa ese abandono con buena anticipacion. El mensaje central: el riesgo no esta repartido al azar, se concentra en momentos y perfiles puntuales, y eso permite actuar con foco en lugar de gastar presupuesto de retencion en toda la base por igual.

16,8%

tasa de churn general
sobre 5.630 clientes (948
se fueron)

52%

de churn en clientes con
0-1 mes de antigüedad,
vs. 6-9% en el resto

x3

la tasa de churn de quien
reclamo, comparada con
quien no reclamo

173/190

clientes que se iban,
detectados a tiempo por el
modelo en la prueba final

LOS TRES HALLAZGOS QUE MAS IMPORTAN

HALLAZGO 1 — ANTIGÜEDAD

El primer mes es el momento de mayor fragilidad. Mas de la mitad de los clientes nuevos que se van, se van antes de cumplir un mes. Pasado ese umbral, el riesgo cae de forma muy pronunciada y se mantiene bajo y estable.

HALLAZGO 2 — EXPERIENCIA Y BENEFICIOS

Quien hizo un reclamo tiene una probabilidad de irse tres veces mayor que quien no reclamo. En paralelo, el 20% de clientes con menos cashback casi triplica la tasa de churn del 20% con mas cashback recibido.

HALLAZGO 3 — LA SORPRESA DEL DATO

La satisfaccion declarada no protege contra el abandono: el grupo que se autocalifica con la nota maxima (5) tiene la tasa de churn mas alta de toda la escala, no la mas baja. Conviene leer la satisfaccion junto con reclamos y antigüedad, no de forma aislada.

COMO SE USA ESTE DOCUMENTO

Las secciones 2 y 3 muestran la evidencia del analisis exploratorio (EDA) con los grupos de mayor riesgo. La seccion 4 explica, en lenguaje simple, como funciona el modelo predictivo y que tan bien anticipa el abandono. La seccion 5 traduce todo en recomendaciones concretas y limitaciones que el equipo de negocio debe resolver antes de implementar.

SOBRE LOS DATOS ANALIZADOS


Base historica de **5.630 clientes** de e-commerce, con 20 variables que cubren antigüedad, comportamiento de compra, beneficios recibidos, satisfaccion declarada y datos demograficos. El dataset original no se modifico en ningun momento del analisis.

Las hipotesis se definieron **antes** de mirar los resultados y se validaron con pruebas estadisticas (Mann-Whitney U para variables numericas, chi-cuadrado para categoricas), reportando siempre el tamano de efecto junto al p-valor.

Todas las cifras de este reporte provienen del analisis exploratorio (*EDA.ipynb*) y del modelado (*Modelo.ipynb*) del proyecto. Las asociaciones reportadas no implican causalidad salvo donde se indique explicitamente.

02 El riesgo se concentra al principio de la relacion

De todas las variables analizadas, la antigüedad del cliente es, por lejos, la señal mas fuerte de abandono. El patron es claro y consistente en todos los segmentos.



LO QUE DICEN LOS NUMEROS


Grupo	Cientes	Antigüedad promedio
Sigue activo	4.676	11,3 meses
Se fue	947	3,6 meses

POR QUE IMPORTA

Un cliente nuevo todavia no genero habito de compra, confianza en la marca ni costo de cambio hacia otro proveedor. Por eso el primer mes concentra el riesgo: es la ventana donde la relacion es mas debil y mas facil de perder.

Implicancia de negocio. Priorizar onboarding, seguimiento activo y pruebas de beneficios durante el primer mes de vida del cliente. La efectividad de estas acciones debe confirmarse con un piloto antes de escalarlas a toda la base nueva.

• Los reclamos anticipan el abandono




Casi 1 de cada 3 clientes que reclamo termino yendose, frente a 1 de cada 9 entre quienes no reclamaron. Es la segunda señal mas clara del analisis y, a diferencia de la antigüedad, es una señal directamente accionable por el equipo de atencion al cliente.

Atencion al usar esta variable. Antes de convertirla en una alerta automatica hay que confirmar que el reclamo quedo registrado antes del abandono y no despues. Si el orden no esta claro, el modelo podria estar "viendo el futuro".

Pruebas estadisticas: Mann-Whitney U para antigüedad ($p < 0,001$, efecto alto) y chi-cuadrado de independencia para reclamos ($p < 0,001$, efecto medio). Base de 5.623 clientes para esta seccion, tras excluir 7 valores extremos puntuales que distorsionaban los graficos.


03 Beneficios, percepcion y segmentos

Mas alla de la antigüedad y los reclamos, otras tres lecturas del EDA ayudan a entender a quien priorizar y, sobre todo, a no sacar conclusiones apresuradas.




El cashback recibido esta asociado con permanencia: a menos beneficio acumulado, mayor tasa de abandono. Recibir mas cashback tambien puede ser consecuencia de comprar mas, no necesariamente su causa.

Recomendacion. Evaluar el cashback como palanca de retencion mediante un piloto controlado, no como campana masiva.



Este resultado contradice la intuicion habitual de negocio: un cliente que se declara satisfecho no esta a salvo de irse.

Recomendacion. Cruzar siempre la satisfaccion declarada con reclamos y antigüedad antes de usarla para decidir a quien contactar.



Categoria de compra preferida y estado civil son los segmentos que mas separan (mayor tamano de efecto estadistico); genero, dispositivo y ciudad pesan menos. Ningun segmento por si solo predice el abandono: funcionan mejor combinados con senales de comportamiento como antigüedad y reclamos.

Variables con efecto bajo en el EDA y sin uso recomendado como argumento aislado: cantidad de cupones usados y dias desde la ultima orden (esta ultima, ademas, mostro una relacion contraria a la esperada y requiere confirmar como fue medida antes de usarla en decisiones comerciales).

04 De los hallazgos a un sistema de alerta temprana

Con estas senales construimos un modelo que asigna a cada cliente un puntaje de riesgo de abandono. No reemplaza el criterio comercial: ordena a la base de clientes para que el equipo de retencion sepa por donde empezar.


COMO FUNCIONA, EN UNA FRASE

El modelo (un Random Forest, una tecnica que combina muchos arboles de decision simples) aprende de los patrones historicos —principalmente antigüedad, frecuencia de compra y cashback recibido— y calcula una probabilidad de abandono para cada cliente nuevo.

El modelo predice 173 de 190 clientes que estaban proximos a irse.

Esa es la metrica que mas importa para negocio: de poco sirve un modelo preciso si deja pasar a la mayoria de los que se van.

Del total de clientes a la deteccion de churn



Lectura: de 190 churns reales en el grupo de prueba, el modelo detecta 173 (91%) priorizando 299 clientes para contacto.

58%

precision: de cada 10 alertas, casi 6 corresponden a un churn real

299

clientes priorizados para contacto sobre una base de prueba de 1.126

QUE SIGNIFICAN ESTOS 4 NUMEROS


810 — activos, el modelo no genero alerta

173 — se iban, y el modelo SI alerto a tiempo

126 — alerta del modelo, pero el cliente se quedo

17 — se fueron sin que el modelo los detectara

El modelo prioriza no dejar pasar churns reales, a costa de generar algunas alertas sobre clientes que en realidad se quedaban: el costo de perder un cliente sin avisar se considera mayor que el costo de un contacto comercial de mas.




Resultado sobre los 1.126 clientes de prueba, nunca vistos por el modelo.

Protocolo: separacion 80/20 sin perfiles duplicados entre entrenamiento y prueba; el conjunto de prueba se evaluo una sola vez, despues de fijar variables, modelo y umbral. Se excluyeron del modelo "Complain" y "DaySinceLastOrder" por no poder confirmar que estuvieran disponibles antes del momento de prediccion (riesgo de fuga de informacion del futuro).

05 Que variables predicen el churn, y como actuar

Mas alla de cuanto detecta el modelo, importa entender en que se basa para decidir: eso confirma que las palancas de abajo tienen respaldo estadistico, no son una intuicion suelta.



Antigüedad y frecuencia de compra explican, por si solas, la gran mayoría de la capacidad del modelo para distinguir quien se va y quien se queda. Esto es consistente con el EDA de las paginas 3 y 4: el modelo confirma y pondera los hallazgos de negocio.

PALANCAS QUE EL EQUIPO COMERCIAL PUEDE MOVER

Senal del modelo	Que indica	Palanca comercial
Tenure bajo (0-1 mes)	Mayor riesgo en el primer mes	Campana de retencion temprana: onboarding y seguimiento activo en las primeras 4 semanas
Complain = si	Probabilidad de irse 3 veces mayor	Atencion prioritaria y flujo de recuperacion dentro de las 48-72h posteriores al reclamo
Cashback bajo	Asociado a menor permanencia	Piloto de cashback reforzado en clientes de riesgo, no campana masiva
Baja frecuencia de compra	Vinculo transaccional debil	Incentivo o recordatorio de recompra para reactivar la frecuencia
Mobile Phone / Solteros	Segmentos con mas churn relativo	Criterio secundario de priorizacion, nunca unico filtro

Estas palancas surgen de asociaciones validadas estadisticamente en el EDA, no de causalidad probada. Antes de escalar cualquiera de ellas, se recomienda un piloto controlado que mida el efecto real sobre la retencion.

06 Limitaciones y proximos pasos

LIMITACIONES A TENER EN CUENTA

Limitacion	Por que importa
Precision de 58%, no de 100%	De cada 10 alertas, casi 6 corresponden a un churn real; las otras 4 son contactos sobre clientes que se iban a quedar. Es el costo de priorizar no dejar pasar churns reales.
Asociacion no es causalidad	Que cashback bajo o reclamos esten asociados al churn no prueba que actuar sobre ellos lo reduzca: hay que medirlo con pilotos antes de escalar.
Reclamos sin temporalidad confirmada	No esta documentado si el reclamo se registro antes o despues del abandono. Por eso se excluyo del modelo automatico.

Validez limitada en el tiempo

El modelo aprendio de un historico puntual; si cambian campanas o comportamiento de compra, su desempeno puede degradarse.

PROXIMOS PASOS

El modelo es una herramienta de priorizacion, no una decision automatica. Antes de escalarlo a produccion, el negocio debe resolver los siguientes puntos.

Pendiente	Por que es necesario
Definir costo de un contacto y de perder un cliente	Permite elegir el umbral de alerta optimo para el presupuesto real
Estimar capacidad semanal/mensual del equipo comercial	Define cuantos clientes priorizados se pueden atender efectivamente
Validar temporalidad de reclamos	Habilita o no usar esta senal como alerta automatica sin fuga de informacion
Disenar pilotos de onboarding y cashback	Las asociaciones no prueban causalidad: hay que medir el efecto real antes de escalar
Monitorear el modelo en produccion	Detectar a tiempo si la precision o el recall se degradan con el tiempo

EN SINTESIS

173/190

clientes que se iban, detectados a tiempo por el modelo

5

palancas comerciales concretas, con respaldo estadistico

5

puntos pendientes para validar antes de escalar a produccion

Detalle metodologico completo, pruebas estadisticas y reproducibilidad en *EDA.ipynb*, *Modelo.ipynb* y *reports/decisions.md* del repositorio del proyecto.