

Por que se nos van los clientes, y que hacer al respecto

Analisis de 5.630 clientes de e-commerce para identificar las senales mas fuertes de abandono y un modelo que prioriza a quien contactar antes de perderlo.

16,8%

de los clientes
abandona la marca

91%

de esos abandonos, el
modelo los detecta a
tiempo

5

hipotesis de negocio
validadas con datos

01 Resumen ejecutivo

Analizamos 5.630 clientes de e-commerce para entender por que abandonan y construimos un modelo que anticipa ese abandono con buena anticipacion. El mensaje central: el riesgo no esta repartido al azar, se concentra en momentos y perfiles puntuales, y eso permite actuar con foco en lugar de gastar presupuesto de retencion en toda la base por igual.

16,8%

tasa de churn general
sobre 5.630 clientes (948
se fueron)

52%

de churn en clientes con
0-1 mes de antigüedad,
vs. 6-9% en el resto

x3

la tasa de churn de quien
reclamo, comparada con
quien no reclamo

91%

de los clientes que se
iban, el modelo los
detecto antes en la prueba
final

LOS TRES HALLAZGOS QUE MAS IMPORTAN

HALLAZGO 1 — ANTIGÜEDAD

El primer mes es el momento de mayor fragilidad. Mas de la mitad de los clientes nuevos que se van, se van antes de cumplir un mes. Pasado ese umbral, el riesgo cae de forma muy pronunciada y se mantiene bajo y estable.

HALLAZGO 2 — EXPERIENCIA Y BENEFICIOS

Quien hizo un reclamo tiene una probabilidad de irse tres veces mayor que quien no reclamo. En paralelo, el 20% de clientes con menos cashback casi triplica la tasa de churn del 20% con mas cashback recibido.

HALLAZGO 3 — LA SORPRESA DEL DATO

La satisfaccion declarada no protege contra el abandono: el grupo que se autocalifica con la nota maxima (5) tiene la tasa de churn mas alta de toda la escala, no la mas baja. Conviene leer la satisfaccion junto con reclamos y antigüedad, no de forma aislada.

COMO SE USA ESTE DOCUMENTO

Las secciones 2 y 3 muestran la evidencia del analisis exploratorio (EDA) con los grupos de mayor riesgo. La seccion 4 explica, en lenguaje simple, como funciona el modelo predictivo y que tan bien anticipa el abandono. La seccion 5 traduce todo en recomendaciones concretas y limitaciones que el equipo de negocio debe resolver antes de implementar.

SOBRE LOS DATOS ANALIZADOS


Base historica de **5.630 clientes** de e-commerce, con 20 variables que cubren antigüedad, comportamiento de compra, beneficios recibidos, satisfaccion declarada y datos demograficos. El dataset original no se modifico en ningun momento del analisis.

Las hipotesis se definieron **antes** de mirar los resultados y se validaron con pruebas estadisticas (Mann-Whitney U para variables numericas, chi-cuadrado para categoricas), reportando siempre el tamano de efecto junto al p-valor.

Todas las cifras de este reporte provienen del analisis exploratorio (*EDA.ipynb*) y del modelado (*Modelo.ipynb*) del proyecto. Las asociaciones reportadas no implican causalidad salvo donde se indique explicitamente.

02 El riesgo se concentra al principio de la relacion

De todas las variables analizadas, la antigüedad del cliente es, por lejos, la señal más fuerte de abandono. El patrón es claro y consistente en todos los segmentos.



LO QUE DICEN LOS NUMEROS


Grupo	Clientes	Antigüedad promedio
Sigue activo	4.676	11,3 meses
Se fue	947	3,6 meses

POR QUÉ IMPORTA

Un cliente nuevo todavía no genera hábito de compra, confianza en la marca ni costo de cambio hacia otro proveedor. Por eso el primer mes concentra el riesgo: es la ventana donde la relación es más débil y más fácil de perder.

Implicancia de negocio. Priorizar onboarding, seguimiento activo y pruebas de beneficios durante el primer mes de vida del cliente. La efectividad de estas acciones debe confirmarse con un piloto antes de escalarlas a toda la base nueva.

• Los reclamos anticipan el abandono




Casi 1 de cada 3 clientes que reclamó terminó yéndose, frente a 1 de cada 9 entre quienes no reclamaron. Es la segunda señal más clara del análisis y, a diferencia de la antigüedad, es una señal directamente accionable por el equipo de atención al cliente.

Atención al usar esta variable. Antes de convertirla en una alerta automática hay que confirmar que el reclamo quedó registrado antes del abandono y no después. Si el orden no está claro, el modelo podría estar "viendo el futuro".

Pruebas estadísticas: Mann-Whitney U para antigüedad ($p < 0,001$, efecto alto) y chi-cuadrado de independencia para reclamos ($p < 0,001$, efecto medio). Base de 5.623 clientes para esta sección, tras excluir 7 valores extremos puntuales que distorsionaban los gráficos.


03 Beneficios, percepcion y segmentos

Mas alla de la antigüedad y los reclamos, otras tres lecturas del EDA ayudan a entender a quien priorizar y, sobre todo, a no sacar conclusiones apresuradas.




El cashback recibido esta asociado con permanencia: a menos beneficio acumulado, mayor tasa de abandono. Recibir mas cashback tambien puede ser consecuencia de comprar mas, no necesariamente su causa.

Recomendacion. Evaluar el cashback como palanca de retencion mediante un piloto controlado, no como campana masiva.



Este resultado contradice la intuicion habitual de negocio: un cliente que se declara satisfecho no esta a salvo de irse.

Recomendacion. Cruzar siempre la satisfaccion declarada con reclamos y antigüedad antes de usarla para decidir a quien contactar.



Categoria de compra preferida y estado civil son los segmentos que mas separan (mayor tamano de efecto estadistico); genero, dispositivo y ciudad pesan menos. Ningun segmento por si solo predice el abandono: funcionan mejor combinados con senales de comportamiento como antigüedad y reclamos.


Variables con efecto bajo en el EDA y sin uso recomendado como argumento aislado: cantidad de cupones usados y dias desde la ultima orden (esta ultima, ademas, mostro una relacion contraria a la esperada y requiere confirmar como fue medida antes de usarla en decisiones comerciales).

04 De los hallazgos a un sistema de alerta temprana

Con estas senales construimos un modelo que asigna a cada cliente un puntaje de riesgo de abandono. No reemplaza el criterio comercial: ordena a la base de clientes para que el equipo de retencion sepa por donde empezar.

COMO FUNCIONA, EN UNA FRASE

El modelo (un Random Forest, una tecnica que combina muchos arboles de decision simples) aprende de los patrones historicos —principalmente antigüedad, frecuencia de compra y cashback recibido— y calcula una probabilidad de abandono para cada cliente nuevo. Se valido sobre 1.126 clientes que el modelo nunca habia visto durante el entrenamiento.



91%


recall: 9 de cada 10 clientes que se iban, el modelo los detecto

58%

precision: de cada 10 alertas, casi 6 corresponden a un churn real

299

clientes priorizados para contacto sobre una base de prueba de 1.126



QUE SIGNIFICAN ESTOS 4 NUMEROS

810 — activos, el modelo no genero alerta

173 — se iban, y el modelo SI alerto a tiempo

126 — alerta del modelo, pero el cliente se quedo


17 — se fueron sin que el modelo los detectara

El modelo prioriza no dejar pasar churns reales, a costa de generar algunas alertas sobre clientes que en realidad se quedaban: el costo de perder un cliente sin avisar se considera mayor que el costo de un contacto comercial de mas.

Resultado sobre los 1.126 clientes de prueba, nunca vistos por el modelo.

Protocolo: separacion 80/20 sin perfiles duplicados entre entrenamiento y prueba; el conjunto de prueba se evaluo una sola vez, despues de fijar variables, modelo y umbral. Se excluyeron del modelo "Complain" y "DaySinceLastOrder" por no poder confirmar que estuvieran disponibles antes del momento de prediccion (riesgo de fuga de informacion del futuro).

05 Que mira el modelo, y que hacer con esto



Antigüedad y frecuencia de compra relativa a la antigüedad explican la gran mayoría de la capacidad de detección. Cashback, cantidad de direcciones registradas, estado civil y satisfacción aportan, pero en una escala mucho menor.

Esto es consistente con el EDA: el modelo no descubrió nada que contradiga los hallazgos de negocio, los confirma y los pondera.

Cuanto empeora la detección del modelo si se "rompe" cada variable. Mas caída, mas relevante.

RECOMENDACIONES

- 1 Reforzar el primer mes.** Diseñar un flujo de onboarding y seguimiento activo durante las primeras 4 semanas, el tramo donde se concentra mas de la mitad del riesgo de abandono.
- 2 Flujo de recuperacion post-reclamo.** Activar una respuesta comercial dentro de los días posteriores a un reclamo, antes de confirmar si puede automatizarse como alerta de modelo (requiere validar la temporalidad del dato).
- 3 Piloto de cashback dirigido.** Probar, sobre una muestra acotada de clientes de riesgo, si aumentar el cashback mejora la retencion de forma medible antes de pensar en una campana masiva.
- 4 Usar el modelo para priorizar, no para decidir solo.** La lista de clientes con alerta debe combinarse con valor del cliente y capacidad real del equipo comercial para definir a quien contactar primero.
- 5 Revisar la satisfaccion con cautela.** No usar el puntaje de satisfaccion como filtro de "cliente seguro"; cruzarlo siempre con antigüedad y reclamos antes de excluir a alguien de una accion de retencion.

ANTES DE IMPLEMENTAR, EL NEGOCIO DEBE RESOLVER

Pendiente	Por que es necesario
Costo de un contacto y de perder un cliente	Permite elegir el umbral de alerta optimo para el presupuesto real
Capacidad semanal/mensual del equipo comercial	Define cuantos clientes priorizados se pueden atender efectivamente
Validar temporalidad de reclamos	Habilita o no usar esta senal como alerta automatica sin fuga de informacion
Piloto de onboarding y cashback	Las asociaciones no prueban causalidad: hay que medir el efecto real

Detalle metodologico completo, pruebas estadisticas y reproducibilidad en *EDA.ipynb*, *Modelo.ipynb* y *reports/decisions.md* del repositorio del proyecto.